

Statistique Bayésienne

Anna Simoni²

²CREST - Ensae and CNRS

- 1 Introduction : les principes Bayésiens
- 2 Principes de vraisemblance et d'exhaustivité

Définition (Modèle classique)

On se place dans un espace probabilisé paramétrique classique :

$$(\mathcal{X}; \mathcal{B}; \{P_\theta, \theta \in \Theta\})$$

où \mathcal{X} désigne l'espace des données, Θ celui des paramètres θ . Le but de l'analyse statistique est de faire de l'inférence sur θ , c'est-à-dire décrire un phénomène passé ou à venir dans un cadre probabiliste.

Un modèle Bayésien est défini par un modèle mesurable équipé d'une mesure μ sur $(\Theta; \mathcal{A})$ (distribution a priori).

Définition (Modèle Bayésien)

Le modèle Bayésien est défini par l'espace probabilisé paramétrique suivant :

$$(\Theta \times \mathcal{X}; \mathcal{A} \otimes \mathcal{B}; \Pi)$$

*où $\Pi = \mu \otimes P_\theta = P \otimes \mu^x$, P est la **probabilité marginale** sur $(\mathcal{X}, \mathcal{B})$ et μ^x est une version régulière de la **probabilité conditionnelle** sur Θ étant donné \mathcal{X} (i.e. probabilité de transition).*

Définition (Modèle classique)

On se place dans un espace probabilisé paramétrique classique :

$$(\mathcal{X}; \mathcal{B}; \{P_\theta, \theta \in \Theta\})$$

où \mathcal{X} désigne l'espace des données, Θ celui des paramètres θ . Le but de l'analyse statistique est de faire de l'inférence sur θ , c'est-à-dire décrire un phénomène passé ou à venir dans un cadre probabiliste.

Un modèle Bayésien est défini par un modèle mesurable équipé d'une mesure μ sur $(\Theta; \mathcal{A})$ (distribution a priori).

Définition (Modèle Bayésien)

Le modèle Bayésien est défini par l'espace probabilisé paramétrique suivant :

$$(\Theta \times \mathcal{X}; \mathcal{A} \otimes \mathcal{B}; \Pi)$$

*où $\Pi = \mu \otimes P_\theta = P \otimes \mu^x$, P est la **probabilité marginale** sur $(\mathcal{X}, \mathcal{B})$ et μ^x est une version régulière de la **probabilité conditionnelle** sur Θ étant donné \mathcal{X} (i.e. probabilité de transition).*

Définition (Modèle classique)

On se place dans un espace probabilisé paramétrique classique :

$$(\mathcal{X}; \mathcal{B}; \{P_\theta, \theta \in \Theta\})$$

où \mathcal{X} désigne l'espace des données, Θ celui des paramètres θ . Le but de l'analyse statistique est de faire de l'inférence sur θ , c'est-à-dire décrire un phénomène passé ou à venir dans un cadre probabiliste.

Un modèle Bayésien est défini par un modèle mesurable équipé d'une mesure μ sur $(\Theta; \mathcal{A})$ (distribution a priori).

Définition (Modèle Bayésien)

Le modèle Bayésien est défini par l'espace probabilisé paramétrique suivant :

$$(\Theta \times \mathcal{X}; \mathcal{A} \otimes \mathcal{B}; \Pi)$$

*où $\Pi = \mu \otimes P_\theta = P \otimes \mu^x$, P est la **probabilité marginale** sur $(\mathcal{X}, \mathcal{B})$ et μ^x est une version régulière de la **probabilité conditionnelle** sur Θ étant donné \mathcal{X} (i.e. probabilité de transition).*

Définition (Modèle dominé)

Le modèle est dit dominé s'il existe une mesure finie commune dominante λ , c'est-à-dire pour tout θ , P_θ admet une densité par rapport à λ :
 $f(X|\theta) := dP_\theta(X)/d\lambda(X)$.

Cette fonction $\ell(\theta|X) := f(X|\theta)$, vue comme une fonction de θ une fois que l'on a observé un tirage de X , est appelée *vraisemblance du modèle*.

Théorème (Théorème de Bayes)

Si A et E sont des événements tels que $P(E) \neq 0$, $P(A|E)$ et $P(E|A)$ sont reliés par

$$P(A|E) = \frac{P(E|A)P(A)}{P(E|A)P(A) + P(E|A^c)P(A^c)} = \frac{P(E|A)P(A)}{P(E)}$$

Définition (Modèle dominé)

Le modèle est dit dominé s'il existe une mesure finie commune dominante λ , c'est-à-dire pour tout θ , P_θ admet une densité par rapport à λ :
 $f(X|\theta) := dP_\theta(X)/d\lambda(X)$.

Cette fonction $\ell(\theta|X) := f(X|\theta)$, vue comme une fonction de θ une fois que l'on a observé un tirage de X , est appelée *vraisemblance du modèle*.

Théorème (Théorème de Bayes)

Si A et E sont des événements tels que $P(E) \neq 0$, $P(A|E)$ et $P(E|A)$ sont reliés par

$$P(A|E) = \frac{P(E|A)P(A)}{P(E|A)P(A) + P(E|A^c)P(A^c)} = \frac{P(E|A)P(A)}{P(E)}$$

Définition (Loi jointe et loi a posteriori)

La *loi jointe* de (X, θ) s'écrit, $\forall B \in \mathcal{B}, \forall A \in \mathcal{A}$:

$$\Pi(B \times A) = \int_A P_\theta(B) d\mu(\theta)$$

et dans le cas d'un modèle dominé (denote $f(x|\theta) := dP_\theta/d\lambda(x)$), alors :

$$\Pi(B \times A) = \int_A \int_B f(x|\theta) d\lambda(x) d\mu(\theta)$$

et $\pi(x, \theta) = f(x|\theta)\mu(\theta)$.

La *loi a posteriori* est définie par sa densité :

$$\mu^x(\theta) := \mu(\theta|x) = \frac{f(x|\theta)\mu(\theta)}{\int f(x|\theta)\mu(\theta)d\theta}. \quad (1)$$

L'inférence bayésienne. IV

- Un modèle statistique Bayésien est constitué d'un modèle statistique paramétrique, $f(x|\theta)$, et d'une distribution a priori pour les paramètres, $\mu(\theta)$.
- En termes statistiques, le théorème de Bayes actualise l'information sur θ en extrayant l'information contenue dans l'observation X .
- La quantité

$$P(X) = \int f(X|\theta)\mu(\theta)d\theta$$

est la **probabilité marginale** de X et est une constante de normalisation de la loi a posteriori, indépendante de θ . On peut donc travailler à une constante multiplicative près : $\mu(\theta|x) \propto f(x|\theta)\mu(\theta)$.

- La **probabilité prédictive** de Y où $Y \sim g(Y|\theta, x)$ est :
 $P(Y|x) = \int g(Y|\theta, x)\mu(\theta|x)d\theta$.

- ① Introduction : les principes Bayésiens
- ② Principes de vraisemblance et d'exhaustivité

Principes de vraisemblance et d'exhaustivité. I

Deux principes fondamentaux sont respectés par le paradigme bayésien : le principe de vraisemblance et le principe d'exhaustivité.

Définition (Exhaustivité)

*Quand $X \sim f(X|\theta)$, une fonction T de X (aussi appelée statistique) est **exhaustive** pour $\{P_\theta, \theta \in \Theta\}$ (ou pour θ) si la distribution de X conditionnellement à $T(X)$ ne dépend pas de θ .*

Théorème (Critère de factorisation)

Une condition nécessaire et suffisante pour qu'une statistique T soit exhaustive pour une famille $\{P_\theta, \theta \in \Theta\}$ de distributions de X dominées par une mesure λ est qu'ils existent deux fonctions non-négatives $g(\cdot|\theta)$ et h telles que :

$$f(x|\theta) = g(T(x)|\theta)h(x) \quad (a.e. \lambda).$$

Théorème (Principe d'Exhaustivité)

Deux observations x et y donnant la même valeur d'une statistique exhaustive T , c'est-à-dire telles que $T(x) = T(y)$, doivent conduire à la même inférence sur θ .

Principes de vraisemblance et d'exhaustivité. I

Deux principes fondamentaux sont respectés par le paradigme bayésien : le principe de vraisemblance et le principe d'exhaustivité.

Définition (Exhaustivité)

Quand $X \sim f(X|\theta)$, une fonction T de X (aussi appelée statistique) est *exhaustive* pour $\{P_\theta, \theta \in \Theta\}$ (ou pour θ) si la distribution de X conditionnellement à $T(X)$ ne dépend pas de θ .

Théorème (Critère de factorisation)

Une condition nécessaire et suffisante pour qu'une statistique T soit exhaustive pour une famille $\{P_\theta, \theta \in \Theta\}$ de distributions de X dominées par une mesure λ est qu'ils existent deux fonctions non-negatives $g(\cdot|\theta)$ et h telles que :

$$f(x|\theta) = g(T(x)|\theta)h(x) \quad (a.e. \lambda).$$

Théorème (Principe d'Exhaustivité)

Deux observations x et y donnant la même valeur d'une statistique exhaustive T , c'est-à-dire telles que $T(x) = T(y)$, doivent conduire à la même inférence sur θ .

Principes de vraisemblance et d'exhaustivité. I

Deux principes fondamentaux sont respectés par le paradigme bayésien : le principe de vraisemblance et le principe d'exhaustivité.

Définition (Exhaustivité)

*Quand $X \sim f(X|\theta)$, une fonction T de X (aussi appelée statistique) est **exhaustive** pour $\{P_\theta, \theta \in \Theta\}$ (ou pour θ) si la distribution de X conditionnellement à $T(X)$ ne dépend pas de θ .*

Théorème (Critère de factorisation)

Une condition nécessaire et suffisante pour qu'une statistique T soit exhaustive pour une famille $\{P_\theta, \theta \in \Theta\}$ de distributions de X dominées par une mesure λ est qu'ils existent deux fonctions non-négatives $g(\cdot|\theta)$ et h telles que :

$$f(x|\theta) = g(T(x)|\theta)h(x) \quad (\text{a.e. } \lambda).$$

Théorème (Principe d'Exhaustivité)

Deux observations x et y donnant la même valeur d'une statistique exhaustive T , c'est-à-dire telles que $T(x) = T(y)$, doivent conduire à la même inférence sur θ .

Principes de vraisemblance et d'exhaustivité. I

Deux principes fondamentaux sont respectés par le paradigme bayésien : le principe de vraisemblance et le principe d'exhaustivité.

Définition (Exhaustivité)

*Quand $X \sim f(X|\theta)$, une fonction T de X (aussi appelée statistique) est **exhaustive** pour $\{P_\theta, \theta \in \Theta\}$ (ou pour θ) si la distribution de X conditionnellement à $T(X)$ ne dépend pas de θ .*

Théorème (Critère de factorisation)

Une condition nécessaire et suffisante pour qu'une statistique T soit exhaustive pour une famille $\{P_\theta, \theta \in \Theta\}$ de distributions de X dominées par une mesure λ est qu'ils existent deux fonctions non-negatives $g(\cdot|\theta)$ et h telles que :

$$f(x|\theta) = g(T(x)|\theta)h(x) \quad (a.e. \lambda).$$

Théorème (Principe d'Exhaustivité)

Deux observations x et y donnant la même valeur d'une statistique exhaustive T , c'est-à-dire telles que $T(x) = T(y)$, doivent conduire à la même inférence sur θ .

Principes de vraisemblance et d'exhaustivité. II

Théorème (Principe de vraisemblance)

L'information apportée par une observation de x sur θ est entièrement contenue dans la fonction de vraisemblance $\ell(\theta|x)$. De plus, si x_1 et x_2 sont deux observations qui dépendent du même paramètre θ , et telles qu'il existe une constante c satisfaisant

$$\ell_1(\theta|x_1) = c\ell_2(\theta|x_2)$$

pour tout θ , elles apportent la même information sur θ et doivent conduire à la même inférence.

Le principe de vraisemblance n'est valide que lorsque

- (i) l'inférence concerne le même paramètre θ et
- (ii) θ prend en compte tous les facteurs inconnus du modèle.

Principes de vraisemblance et d'exhaustivité. III

- L'estimation par maximum de vraisemblance (MV) n'est qu'une façon parmi d'autres de mettre en oeuvre le principe de vraisemblance.
- Si on observe $x \sim f(x|\theta)$, l'approche par MV considère l'estimateur suivant de θ :

$$\hat{\theta} := \arg \sup_{\theta} \ell(\theta|x). \quad (2)$$

- Propriété de l'estimateur du MV est son *invariance par reparamétrisation* : pour toute fonction $h(\theta)$, l'estimateur de MV est $h(\hat{\theta})$ (même quand h n'est pas bijective).

La méthode de MV a aussi des défauts :

1. La maximisation de $\ell(\theta|x)$ peut être assez complexe en pratique, particulièrement dans les cas multidimensionnels ou contraints.
2. Les estimateurs du MV peuvent être numériquement instables, c'est-à-dire peuvent varier considérablement pour de petites variations des observations, du moins pour des tailles d'échantillon réduites.

Principes de vraisemblance et d'exhaustivité. IV

3. L'approche du MV n'admet pas de **justifications probabiliste et décisionnelle**.
De fait, elle ne répond pas aux exigences d'une analyse décisionnelle et échoue ainsi à fournir des outils d'évaluation pour les estimateurs qu'elle propose. Par exemple, il n'est pas possible de faire des tests dans un contexte de MV pur.